IERG4320/IEMS5726 — Chapter 1: Course Introduction — Cheat Sheet

Prof. YAN Wenjing, Dr. Danny Yip | Department of Information Engineering, CUHK

Course Overview (课程概览)

- **Lecture**: Wed 7:00–10:00 pm @ LSB LT6 (12 lectures)
- **Final Exam**: 15 Apr, ERB 1004, open book/note, close internet

Assessment (评分占比)

UReply attendance (签到)	5%
4 Assignments (作业)	35%
Course project (项目, 截止5/8)	20%
Final exam (期末, 开卷)	40%

Fail Conditions (挂科条件)

- Final exam below 30% (期末低于30分)
- Grand total below 40% (总分低于40分)
- Not submitting course project (不交项目直接挂)

AI Tool Policy (AI工具政策)

ChatGPT/DeepSeek/Gemini **allowed** for coursework, but **NOT** for final exam.

作业可以用AI，但必须注明哪些部分用了AI；期末考试不能用。

Key Terminology (核心术语)

Data-related Terms (数据相关)

- **Database** (数据库): organized data collection
  就是把数据整整齐齐存起来，方便查找
- **Data Analysis** (数据分析): get knowledge from data
  从数据里挖出有用的信息
- **Data Mining** (数据挖掘): find patterns in *large* datasets
  在海量数据中找隐藏的规律
- **Big Data** (大数据): dealing with huge, complex data
  数据量大到普通方法处理不了，需要专门技术

AI / ML / DL (三者关系)

- **AI** (人工智能): machines that can think/act smart
  让机器表现出类似人类的智能行为
- **ML** (机器学习): machines learn from data, no need to hard-code rules
  不用写死规则，让机器自己从数据中学习；是AI的子集
- **DL** (深度学习): ML using deep neural networks (many layers)
  用多层神经网络来学习；是ML的子集

Relationship: AI ⊃ ML ⊃ DL
AI最大，ML在AI里面，DL在ML里面，像套娃一样

Roles (数据科学三大岗位)

- **Data Scientist** (数据科学家): turns data into insights & decisions
  从数据中找出有价值的结论，帮助决策
- **ML Engineer** (机器学习工程师): builds ML models into real apps
  把模型落地，做成能用的产品
- **Data Engineer** (数据工程师): builds data pipelines & infrastructure
  搭数据管道，保证数据能顺畅地收集、存储、流转

Data Science (数据科学)

用科学方法从数据中提取知识和洞察，并应用到实际场景中。

Data Science Lifecycle (生命周期)

1. **Data Acquisition** (采集) — collect raw data
2. **Data Cleaning** (清洗) — fix errors, remove noise
3. **Data Modeling** (建模) — build models to find patterns
4. **Data Analysis** (分析) — draw conclusions
5. **Data Visualization** (可视化) — show results with charts

简记：采集 → 清洗 → 建模 → 分析 → 可视化

Related Disciplines (相关学科)

- Computer Science (计算机) — programming, databases
- Statistics (统计学) — interpret results
- Domain knowledge (领域知识) — depends on the problem

Why Data Science Matters (为啥重要)

1. Cost efficient (省钱)
2. Better decision making (帮助做更好的决策)
3. Understand customers (了解用户行为)
4. Manage risks (风险管理)
5. Drive innovation (推动创新)

Classic Examples (经典案例)

1. **MNIST** (手写数字识别) — one of the earliest ML systems
   给机器看手写的0–9，让它自动认出是哪个数字
2. **Recommender Systems** (推荐系统) — e.g. Netflix Prize
   根据你的观影历史，猜你还想看什么电影
3. **Face Detection** (人脸识别) — e.g. Microsoft Face API
   从照片/视频里找到人脸并认出是谁
4. **Machine Translation** (机器翻译) — e.g. Google Translate
   自动把一种语言翻译成另一种
5. **Face Generator** (人脸生成) — GANs
   AI凭空生成逼真的人脸照片
6. **ChatGPT** (聊天机器人) — NLP-powered chatbot
   能像人一样对话，写邮件、写代码

Types of Data Analytics (数据分析类型)

1. **Predictive** (预测型): "What will happen next?"
   预测未来。例：明天要进多少巧克力冰淇淋?
2. **Descriptive** (描述型): "What happened?"
   总结过去。例：上周最受欢迎的口味是什么?
3. **Prescriptive** (建议型): "What should we do?"
   给建议。例：要不要提高巧克力冰淇淋的品质?
4. **Diagnostic** (诊断型): "Why did it happen?"
   找原因。例：为什么巧克力和香草卖得最好?

AI Ethics & Governance (AI伦理与监管)

EU AI Act (欧盟AI法案)

全球第一部AI法规，按风险等级分类管理:

Risk	Examples / Rules
Unacceptable (禁止)	Social scoring, deceptive AI → **banned**
High (高风险)	Medical AI, self-driving → strict review
Limited (有限风险)	ChatGPT, deepfakes → must be transparent
Minimal (低风险)	Spam filters, AI games → self-regulate

HK Ethical AI Framework (香港AI伦理框架, 2024)

数字政策办公室发布，12条原则:

1. Transparency (透明)
2. Reliability & Security (可靠安全)
3. Fairness (公平，不歧视)
4. Diversity & Inclusion (多元包容)
5. Human Oversight (人类监督)
6. Lawfulness (合法合规)
7. Safety (安全)
8. Data Privacy (数据隐私)
9. Accountability (问责)

10. Beneficial AI (有益于社会)
11. Cooperation (开放合作)
12. Sustainability (可持续发展)

Mainland China (中国大陆)

2023年8月起实施《生成式AI服务管理暂行办法》，基于《网络安全法》《数据安全法》《个人信息保护法》。

Course Approach (课程特点)

这门课不只是普通的ML入门课，还会覆盖：

- Data collection & preprocessing (数据收集与预处理)
- Data representation (数据表示)
- Data visualization (数据可视化)
- Domain-specific problems (各领域实际问题)

Prerequisites (先修知识): Statistics, Linear Algebra, Calculus, Probability.

需要统计学、线性代数、微积分、概率论基础。

Course Schedule (课程安排)

#	Topic	Date
1	Course Intro, FastAPI	7/1
2	Basic Statistics (统计)	14/1
3–5	Data Representation (数据表示)	14–28/1
6–7	Data Modeling (建模)	4–11/2
8	Data Visualization (可视化)	25/2
9	Case: Business (商业)	4–11/3
10	Case: Text Mining (文本)	11–18/3
11	Case: Multimedia (多媒体)	18–25/3
12	Case: Game (游戏)	25/3–1/4
13	Summary (总结)	1/4
#	Final Exam	15/4

Python Environment (Python环境)

What is Python? (Python是什么)

- High-level interpreted language (1991, Guido van Rossum)
  高级解释型语言，代码简洁易读
- Current version: Python 3.13 (本课用Anaconda 3.13)

Hello World (第一个程序)

```
# In Python interpreter
>>> print("Hello World!")
Hello World!
```

```
# As a script: helloworld.py
print("Hello World!")
# Run: $ python helloworld.py
```

Common Uses (Python能干啥)

- Web backends (网站后端): YouTube, Reddit
- Data science & ML (数据科学): PyTorch
- Scientific computing (科学计算)
- Data visualization (数据可视化)

Setup (推荐安装)

- **Anaconda** — 1500+ packages, easy to manage
  自带大量数据科学包，装好就能用
- **IDE**: VS Code (免费，好用)

Reference Books (参考书)

1. *Practical Statistics for Data Scientists*
   统计学50个核心概念
2. *Python for Data Analysis*
   Pandas/NumPy实战数据处理
3. *Intro to ML with Python*
   Python机器学习入门
4. *Data Science and Big Data Analytics*
   数据科学全流程+大数据分析
5. *Deep Learning* (Goodfellow)
   深度学习经典教材（花书）

Python Resources (学习资源)

- `docs.python.org/3/` (官方文档)
- `learnpython.org` (交互式教程)
- `w3schools.com/python` (入门教程)